WIELOWYMIAROWA ANALIZA DANYCH STACK OVERFLOW DEVELOPER SURVEY 2025

2025 Developer Survey

POLITECHNIKA GDAŃSKA
WYDZIAŁ ZARZĄDZANIA I EKONOMII

1. Wstęp

1.1. Motywacja i cele

Celem projektu było przeprowadzenie wielowymiarowej analizy sektora IT w 2025 poprzez identyfikację, czynników wpływających na postawy deweloperów wobec narzędzi AI. Motywacją do przeprowadzenia analizy była chęć zrozumienia zależności pomiędzy konkretnymi segmentami branży IT, a postępującym rozwojem narzędzi AI.

1.2. Opis problemu

Podjęty problem badawczo-biznesowy dotyczył potencjalnego zagrożenia dla rynku pracy IT polegającym na zastąpieniu pracowników przez narzędzia IA. Rozważono następujące pytania:

- Na jakie segmenty pod kątem wykorzystywanych technologii dzieli się rynek IT?
- W jakim stopniu przedstawiciele tych grup boją się zastąpienia przez AI?
- W jakim stopniu adoptują się do technologii AI?
- Jak oceniają jakość narzędzi AI w stosunku do ich segmentów technologicznych?

2. Opis danych

Stack Overflow to największa na świecie platforma społecznościowa dedykowana programistom oraz pasjonatom technologii. Użytkownicy mogą tam zadawać szczegółowe pytania techniczne, na które odpowiadają inni członkowie społeczności, tworząc tym samym ogromną bazę wiedzy. Od 2011 roku w ramach platformy corocznie organizowany jest Developer Survey. Ankieta ta zbiera dane od dziesiątek tysięcy specjalistów na temat ich ulubionych technologii, zarobków, preferowanych narzędzi oraz trendów w edukacji i pracy zdalnej. Edycja 2025 jest wyjątkowa - po raz pierwszy w sposób szczególny skupiono się na rozwiązaniach AI.

Parametr	Dane	Próbka
obserwacje	49191	20319
zmienne	172	13
reprezentatywność	1:286	1:1563
rozmiar	88MB	4MB
kompletność	47%	97%

Wykorzystane dane pochodzą z oficjalnej strony Developer Survey. Na ankietę składająca się z 62 pytań odpowiedziało 49191 respondentów. Ze względu na dobrowolny charakter wszystkich pytań oraz warunkowy schemat ankiety kompletność danych jest stosunkowo niska i wynosi ok. 48%. Z racji na tą zależność po wstępnym obejrzeniu zbioru danych, zostały usunięte ankiety osób, które nie określiły z jakich technologii korzystają (języki programowania, bazy danych, frameworki webowe). Dokonano również selekcji pytań. W efekcie baza danych została zmniejszona do 20319 obserwacji z 97% kompletnością wartości. Do realizacji celu projektu wybrano 13 adekwatnych zmiennych spośród 172. Oprócz pytań dotyczących sztucznej inteligencji wzięte pod uwagę zostały również pytania o poziom edukacji, doświadczenia zawodowego, satysfakcji z pracy oraz informacje o wykorzystywanych technologiach.

Skład zmiennych wybranych do analizy oraz odpowiadające im pytania ankietowe:

- “WorkExp” Ile masz lat doświadczenia zawodowego?
- “EdLevel” Jaki jest twój poziom wykształcenia formalnego?
- “JobSat” Jaki odczuwasz poziom satysfakcji z roli dewelopera?
- “AIThreat” Czy AI to zagrożenie dla pracy?
- “AISelect” Czy używasz narzędzi AI w pracy?
- “AISent” Jaki jest twój stosunek do używania AI?
- “AIAcc” Jakie jest twoje zaufanie do dokładności AI?
- “AIComplex” Jak oceniasz radzenie sobie AI ze złożonymi zadaniami?
- “AIAgents” Czy używasz agentów AI?

3. Obróbka zmiennych

3.1. Tworzenie nowych zmiennych

W analizowanej ankiecie pytania dotyczące wykorzystywanych technologii (pytania osobno o języki programowania, frameworki webowe oraz systemy baz danych były pytaniami wielokrotnego wyboru. W zbiorze danych odpowiedzi te występowały w postaci nazw technologii które były oddzielone od siebie średnikami, osobno dla każdej kategorii. W celu dostosowania danych do analizy zastosowano kodowanie binarne. Przekształcono każdą technologię na zmienną binarną (*dummy variable*) w której 1 oznacza znajomość technologii a 0 brak znajomości. W wyniku przekształceń uzyskano 100 zmiennych które reprezentują 100 unikalnych technologii.

Pytania dotyczące stosunku respondeta do narzędzi AI a także te definiujące jego profil społeczny i zawodowy występowały w skali Likerta. Zastosowano wobec nich kodowanie polegające na zastąpieniu wartości tekstowych na zmienne kategoryczne uporządkowane. Zmienne ciągłe (np. doświadczenie zawodowe) przekształcono na zmienne kategoryczne uporządkowane, w procesie tym obsłużono również wartości odstające, definiując je jako nierealne/niereprezentatywne (np. 70 lat doświadczenia zawodowego) i potraktowano je jako braki danych.

3.2. Standaryzacja i normalizacja

Dane dotyczące technologii są danymi binarnymi. Dla zastosowanych metod nie jest konieczna standaryzacja i normalizacja. Dane kategoryczne uporządkowane zostały przetwarzane w dalszych punktach przez macierz polichoryczną co zastąpiło wspomniane operacje.

4. Analiza eksploracyjna danych

4.1. Podstawowe statystyki opisowe

4.1.1. Zmienne binarne

W branży IT przeciętnie każdy specjalista zna 6 języków programowania. Rozrzut jest niewielki – większość osób zna od 5 do 8 języków. W przypadku baz danych mediana wynosi 3, natomiast wartości kwartyli to odpowiednio: Q1 = 2 oraz Q3 = 5. Oznacza to, że pracownicy zazwyczaj operują na 2–3 bazach, podczas gdy eksperci posługują się nawet ośmioma. W obszarze frameworków webowych różnice w znajomości technologii między ekspertami a juniorami są mniejsze. Mediana wynosi tutaj 3, a eksperci deklarują znajomość 5 technologii.

Kategoria	Q1	Mediana	Q3
Liczba znanych systemów baz danych	2	3	5
Liczba znanych języków programowania	5	6	8
Liczba znanych frameworków webowych	2	3	5

4.1.2. Zmienne kategoryczne

Zmienna	Min	Q1	Mediana	Q3	Max
AIAcc	1	2	3	4	5
AIAgents	0	0	1	4	5
AIComplex	1	2	3	4	5
AISelect	0	2	4	4	4
AISent	1	3	4	4	5
AIThreat	0	0	0	1	2
EdLevel	1	5	5	6	7
JobSat	0	2	3	3	4
LearnCodeAI	0	1	2	3	3
WorkExp	0	1	3	3	4

Analiza podstawowych statystyk dla 10 pytań, które zakodowane zostały jako zmienne kategoryczne uporządkowane w skład których wchodzą także zmienne w skali Likerta ujawniła sporo wniosków dotyczących respondentów. Najsilniejsze trendy widać w zmiennych dotyczących ogólnego nastawienia i częstotliwości pracy z nową technologią. Zmienna AISent , odpowiadająca na pytanie o ogólny stosunek do AI, posiada medianę na poziomie 4, co oznacza, że typowy deweloper ocenia tę technologię jako pozytywną. Współgra to z wynikiem zmiennej AISelect (częstotliwość użycia), gdzie mediana wynosząca 4 wskazuje na codzienne wykorzystywanie narzędzi AI w

pracy. Co niezwykle istotne, zmienna AIThreat (pytanie o zagrożenie dla pracy ze strony AI) ma medianę 0, co oznacza stanowczą odpowiedź "nie". Sugeruje to, że deweloperzy traktują AI jako codzienne wsparcie, a nie konkurencję. Mimo wysokiego entuzjazmu, programiści zachowują dystans do AI w kwestiach technicznych. Zmienne AIAcc (zaufanie do dokładności wyników) oraz AIComplex (ocena radzenia sobie ze złożonymi zadaniami) mają mediany równe 3. Oznacza to postawę neutralną („ani ufam, ani nie ufam" oraz „ani dobrze, ani źle"). Oznacza to, że typowy respondent nie ufa AI bezkrytycznie. Podobnie sytuacja wygląda przy AIAgents (używanie agentów AI), gdzie mediana 1 wskazuje na etap planowania wdrożenia w najbliższej przyszłości, co pokazuje, że rok 2025 to czas przejścia od prostych asystentów kodu do bardziej złożonych systemów agentowych. Statystyczny obraz dopełniają zmienne demograficzne i zawodowe, które świadczą o wysokim profesjonalizmie badanej grupy. Zmienna EdLevel z medianą 5 wskazuje, że typowy respondent posiada tytuł licencjata lub inżyniera. W połączeniu z medianą 3 dla WorkExp (co w oznacza staż między 11 a 20 lat), widzimy, że ankieta dotarła do dojrzałych, doświadczonych pracowników. Grupa ta jest przy tym zadowolona ze swojej ścieżki zawodowej JobSat z medianą 3 (odpowiednik punktacji 7–8 w skali 10-stopniowej) świadczy o wysokiej satysfakcji z pracy.

Warto zwrócić uwagę na zmienną LearnCodeAI, która pyta o to, czy i w jakim celu deweloper uczył się programowania z AI w ostatnim roku. Mediana na poziomie 2 oznacza, że statystyczny programista podjął wysiłek nauki z własnej ciekawości lub hobbystycznie. Choć codzienne użycie jest wysokie (mediana 4), to systematyczne szkolenie ukierunkowane stricte na rozwój kariery (wartość 3) nie stało się jeszcze standardem dla większości, co sugeruje ogromne pole do wzrostu w obszarze profesjonalnej edukacji AI.

4.2. Analiza rozkładów

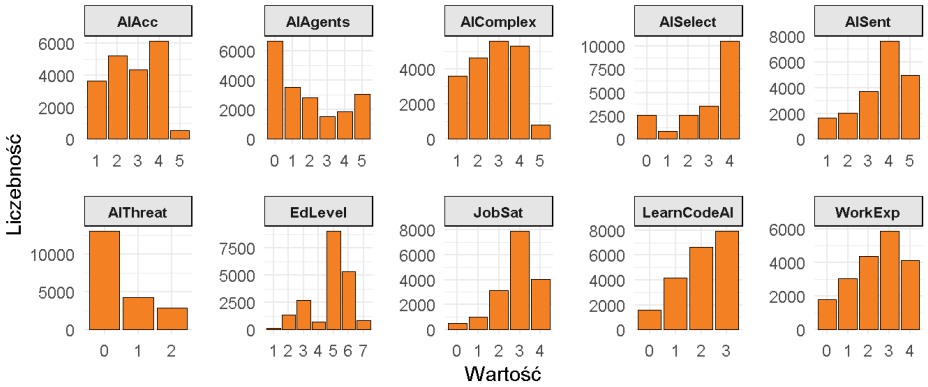

Lata doświadczenia wykazuje silną skośność prawostronną, co oznacza dominację osób o krótszym stażu pracy Junior i MID, sukcesywny spadek liczebności w grupach o dłuższym doświadczeniu. Języki programowania posiada rozkład zbliżony do symetrycznego z medianą wynoszącą 6, co wskazuje na stabilną i wysoką wszechstronność technologiczną w całej badanej populacji. Bazy danych i frameworki charakteryzują się rozkładem symetrycznym o niewielkim rozstępie, co sugeruje dużą specjalizację programistów skupionych wokół 2–3 kluczowych technologii. Korzystanie z AISelect i AIAgents wykazuje wyraźną skośność lewostronną, wynikającą z bardzo wysokiej adaptacji narzędzi AI i ich codziennego wykorzystywania przez większość respondentów. Zaufanie i stosunek do AI posiada rozkład lewostronny, co potwierdza przewagę postaw entuzjastycznych oraz wysoki stopień zaufania do dokładności generowanych rozwiązań. Poziom wykształcenia ma silną skośność lewostronną, ponieważ masa rozkładu koncentruje się przy najwyższych wartościach skali studia wyższe licencjackie i magisterskie. Zagrożenie ze strony AI wykazuje skośność prawostronną, co obrazuje fakt, że większość deweloperów nie postrzega sztucznej inteligencji jako zagrożenia dla ich obecnego miejsca pracy. Satysfakcja z pracy charakteryzuje się rozkładem bliskim symetrycznemu, co wskazuje na stabilny i relatywnie wysoki poziom zadowolenia zawodowego w branży. Analiza histogramów pozwala dostrzec, nowe zależności w odpowiedziach ankietowych i stwierdzić czy omówione wcześniej mediany wynikają z powszechnego konsensusu, czy może z polaryzacji opinii wśród deweloperów. W obszarze adopcji i ogólnego nastawienia do technologii, histogramy wykazują wyraźną asymetrię lewostronną, co świadczy o silnie ugruntowanych, pozytywnych trendach. W przypadku zmiennej AISelect najwyższy słupek odpowiada wartości 4, co potwierdza, że codzienne wykorzystywanie narzędzi AI stało się powszechnym standardem pracy.

Podobny trend widać w zmiennej AISent, gdzie liczebność odpowiedzi koncentruje się niemal wyłącznie przy wartościach 4 (pozytywne) oraz 5 (bardzo pozytywne), przy marginalnym udziale głosów krytycznych. Najbardziej uderzający jest jednak rozkład zmiennej AIThreat. Dominujący, wysoki słupek przy wartości 0 wizualnie

dowodzi, że deweloperzy niemal jednogłośnie odrzucają obawę o zastąpienie ich roli przez sztuczną inteligencję. Zupełnie inny charakter mają rozkłady zmiennych dotyczących zaufania i zaawansowanych narzędzi, gdzie obserwujemy kształt zbliżony do rozkładu normalnego, co wskazuje na większą ostrożność badanych. Histogramy dla AIAcc (zaufanie do dokładności AI) oraz AIComplex (ocena złożoności zadań) mają swoje szczyty przy wartościach 3 i 4, co obrazuje, że deweloperzy doceniają narzędzia, ale rzadko przyznają im najwyższy stopień bezbłędności. Szczególnie interesujący jest wykres AIAgents, który pokazuje najwyższą liczebność przy wartości 0 oraz 1, ale posiada również wyraźną grupę odpowiedzi przy wartościach 4 i 5. Sugeruje to istnienie dwóch odrębnych grup użytkowników: większości, która jeszcze nie wdrożyła agentów AI, oraz dynamicznej mniejszości, która korzysta z nich bardzo intensywnie. Wykresy opisujące status zawodowy i satysfakcję potwierdzają, że badana próba składa się z ustabilizowanych profesjonalistów. Histogram EdLevel posiada najwyższe wartości przy wartościach 5 i 6, co odpowiada osobom z wykształceniem wyższym na poziomie licencjata/inżyniera lub magistra. Z kolei rozkład WorkExp skupia się wokół wartości 3, co wizualizuje przewagę deweloperów o stażu między 11 a 20 lat, tworząc obraz dojrzałego rynku pracy. Satysfakcja zawodowa, mierzona zmienną JobSat, również wykazuje skupienie przy wysokich wartościach 3 i 4, co świadczy o tym, że obecna transformacja technologiczna nie wpłynęła negatywnie na dobrostan psychiczny pracowników IT. Ostatnim istotnym elementem jest zmienna LearnCodeAI, której histogram pokazuje dwa niemal równe i wysokie słupki przy wartościach 2 i 3. Obrazuje to masową skalę procesu edukacyjnego. Deweloperzy w równym stopniu inwestują czas w naukę AI z pobudek hobbystycznych, jak i w celu rozwoju kariery zawodowej.

4.3. Analiza korelacji

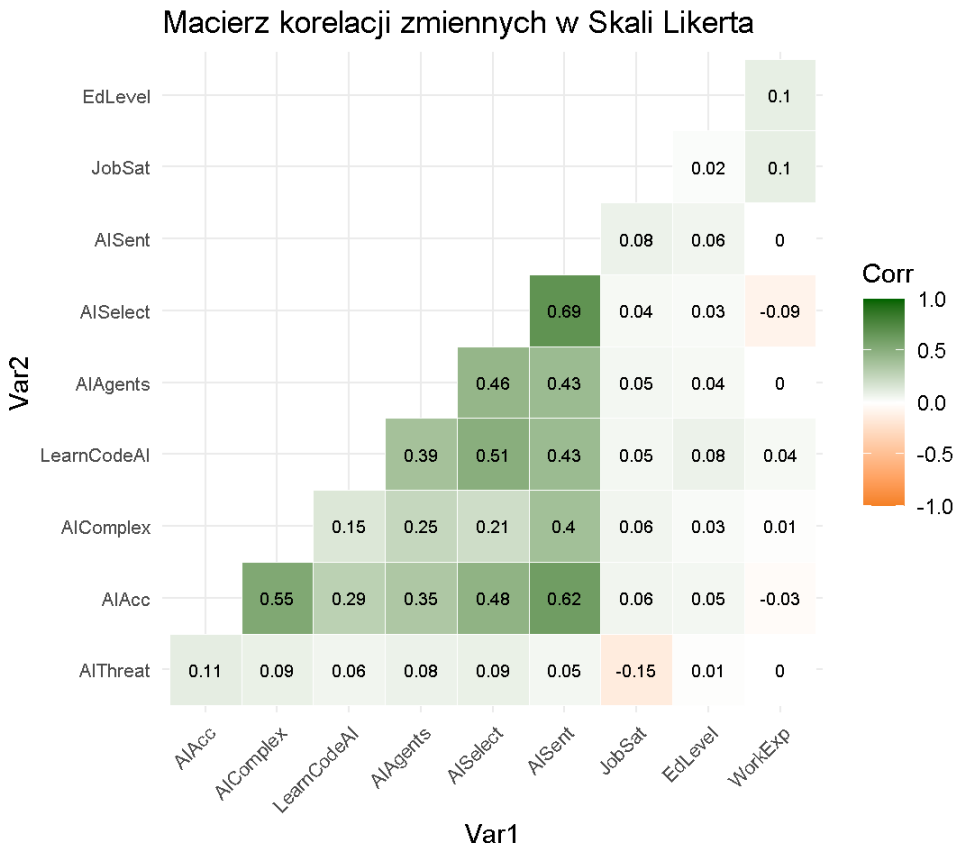

Prezentowana macierz korelacji Pearsona stanowi punkt wyjścia dla eksploracyjnej analizy czynnikowej, wizualizując siłę i kierunek powiązań między badanymi zmiennymi. Dominacja koloru zielonego w dolnym lewym rogu macierzy wskazuje na istnienie silnych, dodatnich korelacji w obszarze postaw wobec AI, co potwierdza zasadność poszukiwania ukrytych wymiarów wspólnych. Najsilniejsze korelacje w zbiorze danych koncentrują się wokół zmiennych nastawienie, użytkowanie oraz zaufanie do AI. Najsilniejsza zależność w całej macierzy, wynosząca 0.69 dotyczy nastawienia do AI oraz użycia technologii AI. Wskazuje ona, że deweloperzy o pozytywnym stosunku do AI są najbardziej skłonni do wdrażania tych narzędzi w swojej codziennej rutynie pracy. Bardzo silna korelacja dodatnia nastawienia do AI oraz zaufania (AIAcc) na poziomie 0.62 dowodzi, że ogólny entuzjazm wobec technologii jest ściśle powiązany z subiektywną oceną jej dokładności.

4.4. Analiza braków danych

Skala braków danych w badanym zbiorze jest zróżnicowana, jednak dla większości zmiennych utrzymuje się na niskim poziomie poniżej 5%. Taki poziom braków danych można efektywnie uzupełnić metodami imputacji. Jedyną zmienną, która znacznie wyróżnia się na tle innych pod kątem ilości brakujących wartości jest poziom satysfakcji z brakami wynoszącymi 18,57%. Jest to bardzo duża ilość sugerująca odrzucenie zmiennej, lecz zdecydowano o pozostawieniu jej ze świadomością, że jakość tej zmiennej po imputacji obniży się.

Nazwa zmiennej	Liczba braków (N)	Udział braków (%)
JobSat	3774	18.57
WorkExp	1122	5.52
AIAgents	772	3.80
AIAcc	378	1.86
AIComplex	376	1.85
AISent	322	1.58
AISelect	264	1.30
EdLevel	243	1.20
AIThreat	138	0.68
LearnCodeAI	35	0.17
num_langs	0	0.00
num_dbs	0	0.00
num_webs	0	0.00

MCAR - test zależności braków danych

```
## # A tibble: 1 × 4
##   statistic    df p.value missing.patterns
##       <dbl> <dbl>   <dbl>            <int>
## 1     3960.   745       0               80
```

Wartość p-value równa 0 oznacza odrzucenie hipotezy zerowej mówiącej o tym, że dane są brakujące całkowicie losowo (missing completely at random). Oznacza to, że braki w danych mają charakter nielosowy. Istnieje systematyczna zależność między występowaniem braków a wartościami innych zmiennych w zbiorze.

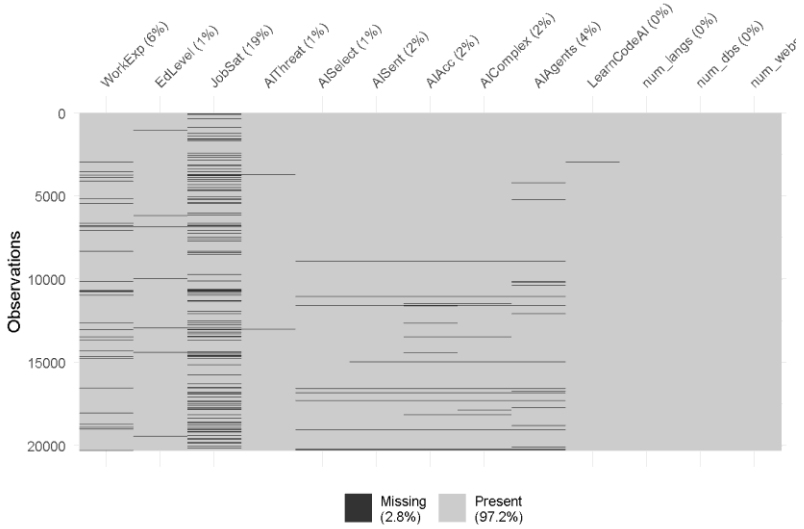

Wizualizacja braków danych, stanowi graficzne uzupełnienie wcześniejszej analizy statystycznej. Wykres prezentuje macierz danych, w której kolumny odpowiadają zmiennym, a wiersze poszczególnym obserwacjom, przy czym kolorem czarnym oznaczono wartości brakujące. Głównym wnioskiem płynącym z wizualizacji jest bardzo wysoka ogólna kompletność danych, która wynosi 96,3%, przy globalnym odsetku braków na poziomie zaledwie 3,7%. Najbardziej uderzającym elementem wykresu jest kolumna zmiennej JobSat, która wykazuje najwyższą gęstość czarnych linii, co odpowiada 19% braków danych w tej zmiennej.

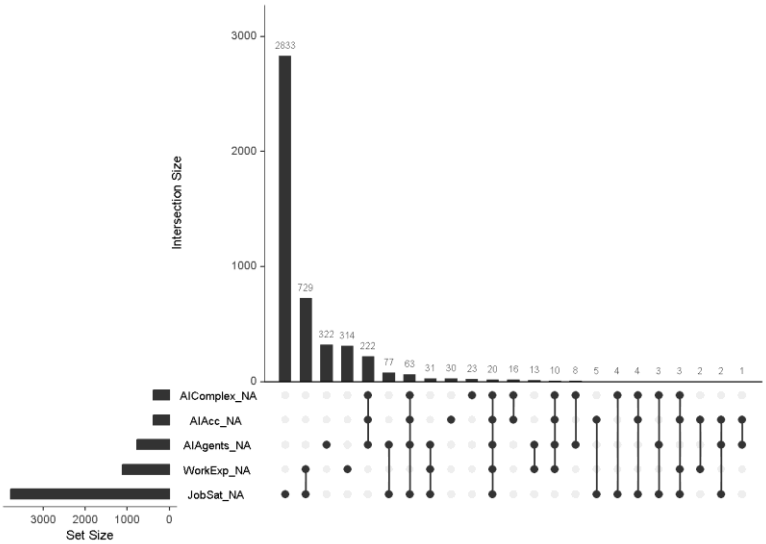

Wykres UpSet, pozwala na precyzyjną analizę współwystępowania braków danych pomiędzy różnymi zmiennymi, co jest kluczowe dla zrozumienia nielosowego charakteru brakujących informacji. Najwyższy pionowy słupek wskazuje, że zdecydowana większość osób, które nie odpowiedziały na pytanie o satysfakcję, wypełniła poprawnie wszystkie pozostałe sekcje ankiety. Drugi co do wielkości wzorzec pokazuje silną zależność, że respondenci pomijający pytanie o staż pracy niemal zawsze pomijali również pytanie o satysfakcję zawodową. Istotna grupa osób pominęła całą sekcję techniczną dotyczącą zaufania i złożoności AI, co sugeruje, że braki te wynikają z braku doświadczenia z tymi narzędziami u części programistów.

4.5. Analiza obserwacji odstających

W badanym zbiorze danych zlokalizowano wartości odstające w zmiennej dotyczącej doświadczenia zawodowego, wynikające z wielkości powyżej 50 lat doświadczenia, lecz już na poziomie przekodowania zmiennych obserwacje te zostały usunięte. Poza tą zmienną nie stwierdzono obecności istotnych obserwacji odstających. Brak klasycznych outlierów wynika bezpośrednio ze struktury wybranych zmiennych. Większość zmiennych została zmierzona na skali Likerta. Ponieważ odpowiedzi są ograniczone do zamkniętego, wąskiego przedziału występowanie outlierów jest niemożliwe. Podobnie jest w przypadku innych zmiennych kategorycznych oraz zmiennych binarnych.

5. Czyszczenie danych

5.1. Obsługa braków wartości

Proces uzupełniania braków danych w projekcie został przeprowadzony przy użyciu zaawansowanego algorytmu MICE, co było podyktowane nielosowym charakterem brakujących informacji zidentyfikowanym w teście Little'a. Zastosowana procedura opiera się na metodzie imputacji wielokrotnej, która zamiast zastępować brak jedną wartością, tworzy kilka kompletnych zbiorów danych, co pozwala na zachowanie naturalnej zmienności i korelacji między zmiennymi. Jest to szczególnie istotne dla zmiennej odnoszącej się do satysfakcji z pracy, gdzie skala braków wynosiła aż 18.57%.

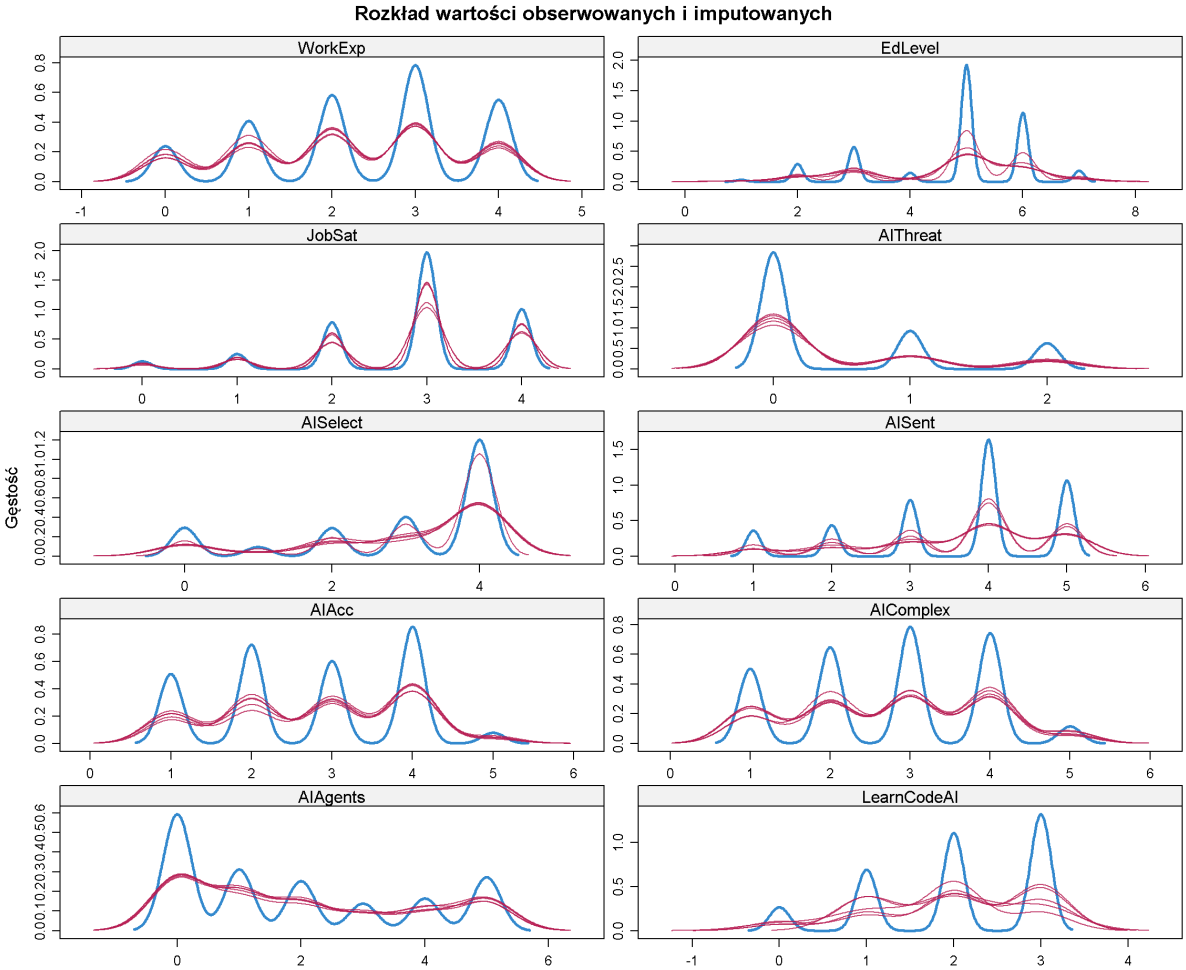

Wykresy gęstości, których zadaniem było porównanie rozkładu danych obserwowanych z rozkładem danych uzupełnionych. Dzięki zastosowaniu metody Predictive Mean Matching, krzywe gęstości dla danych imputowanych niemal w pełni odwzorowują trend oryginalnego rozkładu, co dowodzi, że proces uzupełniania braków nie zniekształcił struktury danych ani nie wprowadził do modelu sztucznych

anomalii statystycznych. Całość diagnostyki dopełniła analiza wykresów punktowych rozrzutu Stripplots. Pozwoliły one ostatecznie zweryfikować, czy wszystkie wartości uzupełnione przez algorytm mieszczą się w dopuszczalnym zakresie merytorycznym.

5.2. Obsługa obserwacji odstających

Obsługa obserwacji odstających została opisana w punkcie 4.5.

6. Metodyka

6.1. Wielowymiarowa Analiza Korespondencji

W celu pogrupowania technologii i wyodrębnienia z nich spójnych grup zastosowano Wielowymiarową Analizę Korespondencji (MCA). Została ona wybrana, ponieważ bardzo dobrze wpisuje się w charakter danych kategorycznych binarnych i porządkowych. Metoda MCA pozwala na stworzenie mapy percepcyjnej, na której odległości między punktami reprezentują podobieństwo technologii.

W celu osiągnięcia wyżej wymienionych efektów, ostatecznie do analizy wybrano zmienne binarne powstałe na skutek przekształcenia zmiennych:

- “LanguageHaveWorkedWith” (Z jakich języków programowania korzystasz?)
- “DatabaseHaveWorkedWith” (Z jakich bazy danych korzystasz?)
- “WebframeHaveWorkedWith” (Z jakich frameworków webowych korzystasz?)

Zachowano jedynie te technologie, które są używane przez co najmniej 1% badanej populacji. Pozwoliło to na zredukowanie liczby analizowanych narzędzi ze 100 do 92 najistotniejszych rynkowo pozycji. Ostatecznym wynikiem jest dwuwymiarowy wykres zmiennych, na którym technologie współwystępujące ze sobą w rzeczywistych projektach znajdują się bliżej siebie.

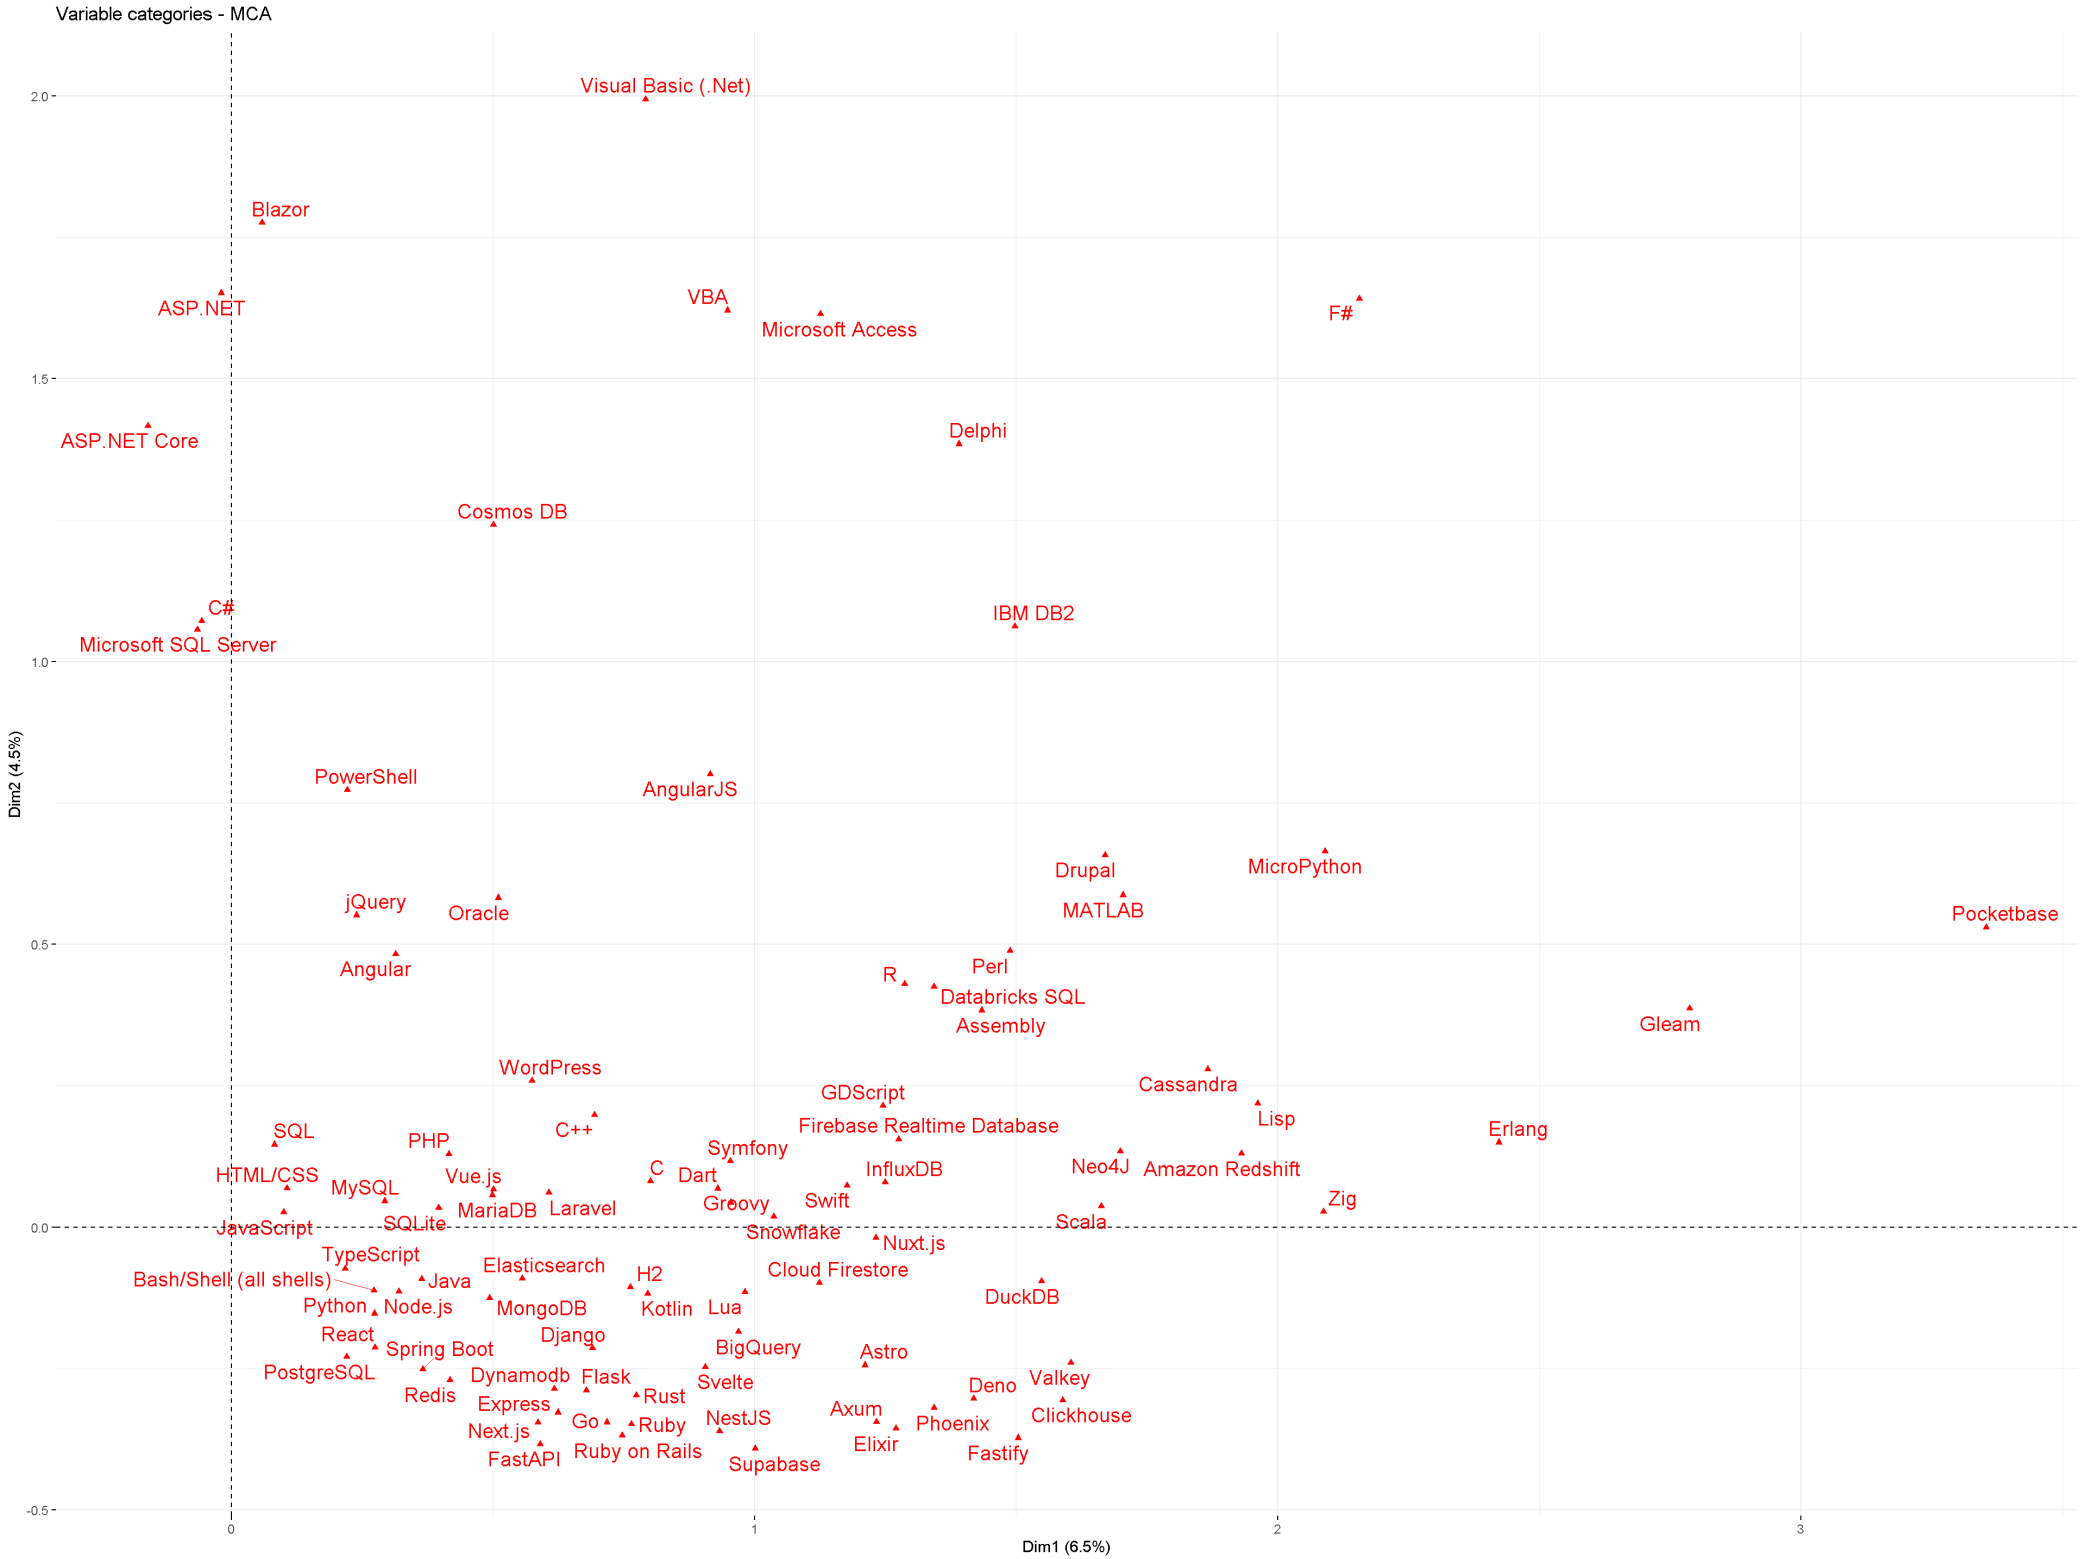
Variable categories - MCA
Visual Basic (.Net)
Blazor
ASP.NET
VBA
Microsoft Access
F#
ASP.NET Core
Delphi
Cosmos DB
C#
Microsoft SQL Server
IBM DB2
PowerShell
AngularJS
Drupal
MicroPython
jQuery
Oracle
MATLAB
Pocketbase
Angular
R
Perl
Databricks SQL
Assembly
Gleam
WordPress
GDScript
Cassandra
Lisp
SQL
PHP
C++
Firebase Realtime Database
Erlang
Symfony
HTML/CSS
MySQL
Vue.js
C
Dart
InfluxDB
Neo4J
Amazon Redshift
Zig
MariaDB
Laravel
Groovy
Swift
JavaScript
SQLite
Snowflake
Scala
Nuxt.js
TypeScript
Elasticsearch
H2
Cloud Firestore
Bash/Shell (all shells)
Java
Python
Node.js
MongoDB
Kotlin
Lua
DuckDB
React
Spring Boot
Django
BigQuery
Astro
PostgreSQL
Redis
Dynamodb
Flask
Svelte
Deno
Valkey
Express
Rust
Axum
Clickhouse
Next.js
Go
Ruby
NestJS
Phoenix
FastAPI
Ruby on Rails
Elixir
Fastify
Supabase
Dim1 (6.5%)
Dim2 (4.5%)
2.0
1.5
1.0
0.5
0.0
-0.5
0
1
2
3

Analiza MCA pozwoliła na wizualizację „przestrzeni technologicznej”, przekształcając binarne dane o używanych narzędziach w mapę współrzędnych. Na zaprezentowanym wykresie, osie 1 (6,5% wyjaśnianej wariancji) oraz 2 (4,5% wyjaśnianej wariancji) definiują główne kierunki polaryzacji współczesnego ekosystemu IT. Z obserwacji wynika, że wymiar 1 opisuje popularność technologii. Lewa strona wykresu grupuje technologie o charakterze ogólnym i bardzo wysokiej popularności (np. JavaScript, Python, HTML/CSS). Im dalej w prawą stronę, tym częściej pojawiają się języki niszowe, funkcyjne lub wysokowydajne, takie jak Rust, Elixir, Erlang, Zig czy Haskell. Wymiar 2 odnosi się do nowoczesności technologii. Górna część wykresu wyraźnie oddziela technologie kojarzone z tradycyjnymi środowiskami korporacyjnymi i ekosystemem Microsoft (np. Visual Basic (.Net), VBA, Microsoft Access, ASP.NET). Dolna część skupia nowoczesne frameworki webowe i rozwiązania cloud-native, takie jak FastAPI, Next.js, NestJS czy Svelte.

Wizualizacja ujawnia także istnienie wyraźnych „wysp” technologicznych, które często występują wspólnie w profilach zawodowych:

- Skupisko enterprise Microsoft (górny lewy kwadrant) skupia deweloperów pracujących w ekosystemie .NET. Widoczne są tu silne powiązania między C#, ASP.NET Core, SQL Server oraz narzędziami automatyzacji biurowej, takimi jak VBA.
- Skupisko Modern Fullstack & Startup (dolny lewy kwadrant) to najbardziej zagęszczony obszar, obejmujący React, TypeScript, Node.js, PostgreSQL oraz Redis. Technologie te znajdują się blisko środka osi pionowej, co sugeruje, że stanowią one obecny „standard rynkowy”.
- Skupisko Data Science & Research (środkowy prawy obszar). Widoczne jest tu zgrupowanie technologii analitycznych, gdzie Python łączy się z narzędziami takimi jak R, MATLAB, Snowflake oraz Databricks SQL.
- Skupisko systemowe i niszowe (prawy dolny kwadrant). Zawiera technologie o wysokim stopniu skomplikowania, często wybierane przez pasjonatów lub do specyficznych zastosowań (np. Lisp, Fortran, Ada, Phoenix).

Niska wartość wyjaśnianej wariancji (łącznie 11% dla dwóch osi) jest typowa dla MCA przy tak dużej liczbie zmiennych. Potwierdza to ogromne rozproszenie i różnorodność narzędzi używanych przez deweloperów w 2025 roku. Mimo to, odległości na mapie dobrze tłumaczą strukturę.

Przekształcono wyniki MCA w segmentację technologii za pomocą klastrowania hierarchicznego. Przeprowadzono ten proces, aby zamienić mapę punktów w konkretne, logiczne grupy widoczne na dendrogramie. Wykorzystano metodę klastrowania Warda, która dąży do minimalizacji wariancji wewnątrz klastrów.

6.2. Klastrowanie Hierarchiczne na wynikach MCA

W celu wyodrębnienia spójnych klastrów technologicznych i nazwania ich przeprowadzono Klastrowanie Hierarchyczne (HC) na wynikach uzyskanych dzięki redukcji wymiarów MCA.

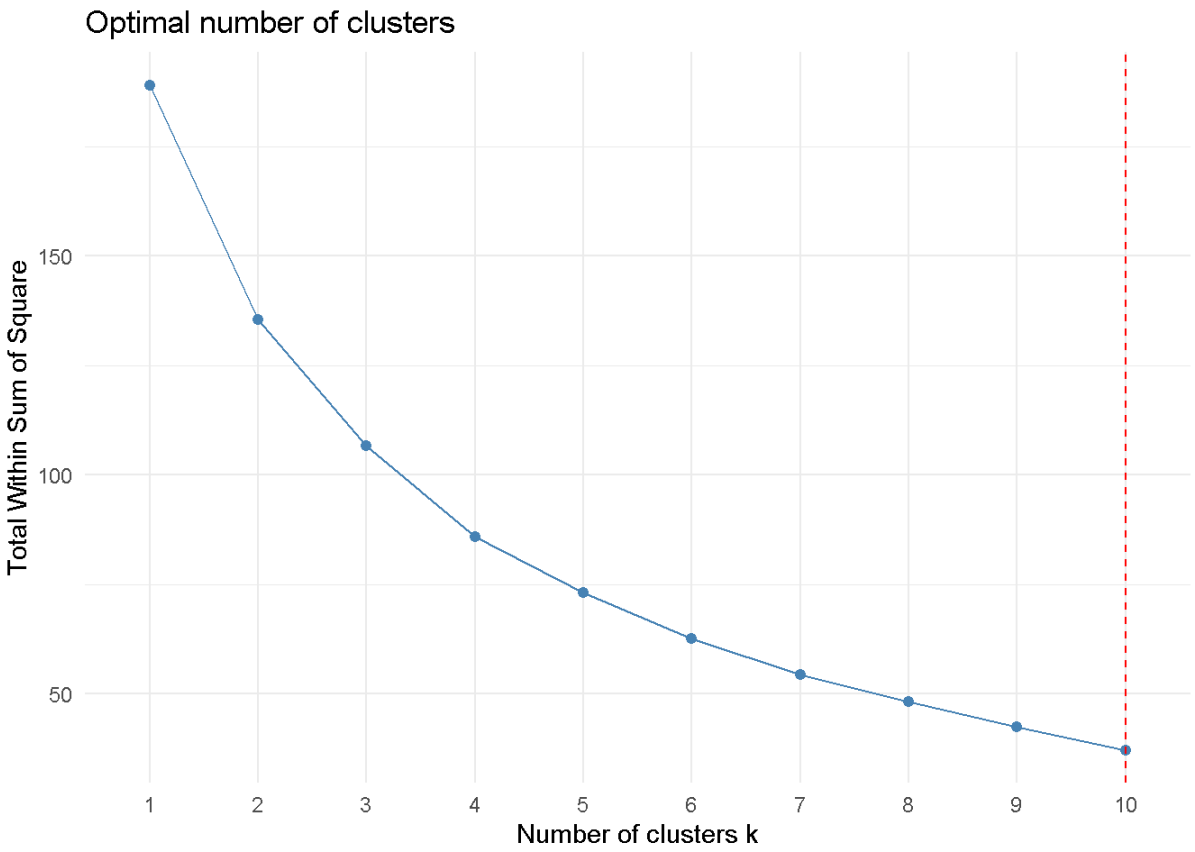

W celu wyznaczenia optymalnej liczby klastrów technologicznych przeprowadzono analizę metodą łokcia (WSS). Wykres nie zobrazował jednoznacznego przegięcia na wykresie. W celu wyodrębninienia jak najbardziej specjalistyczhc grup technologi zdecydowano o przyjęciu 10 klastrów.

Cluster Dendrogram

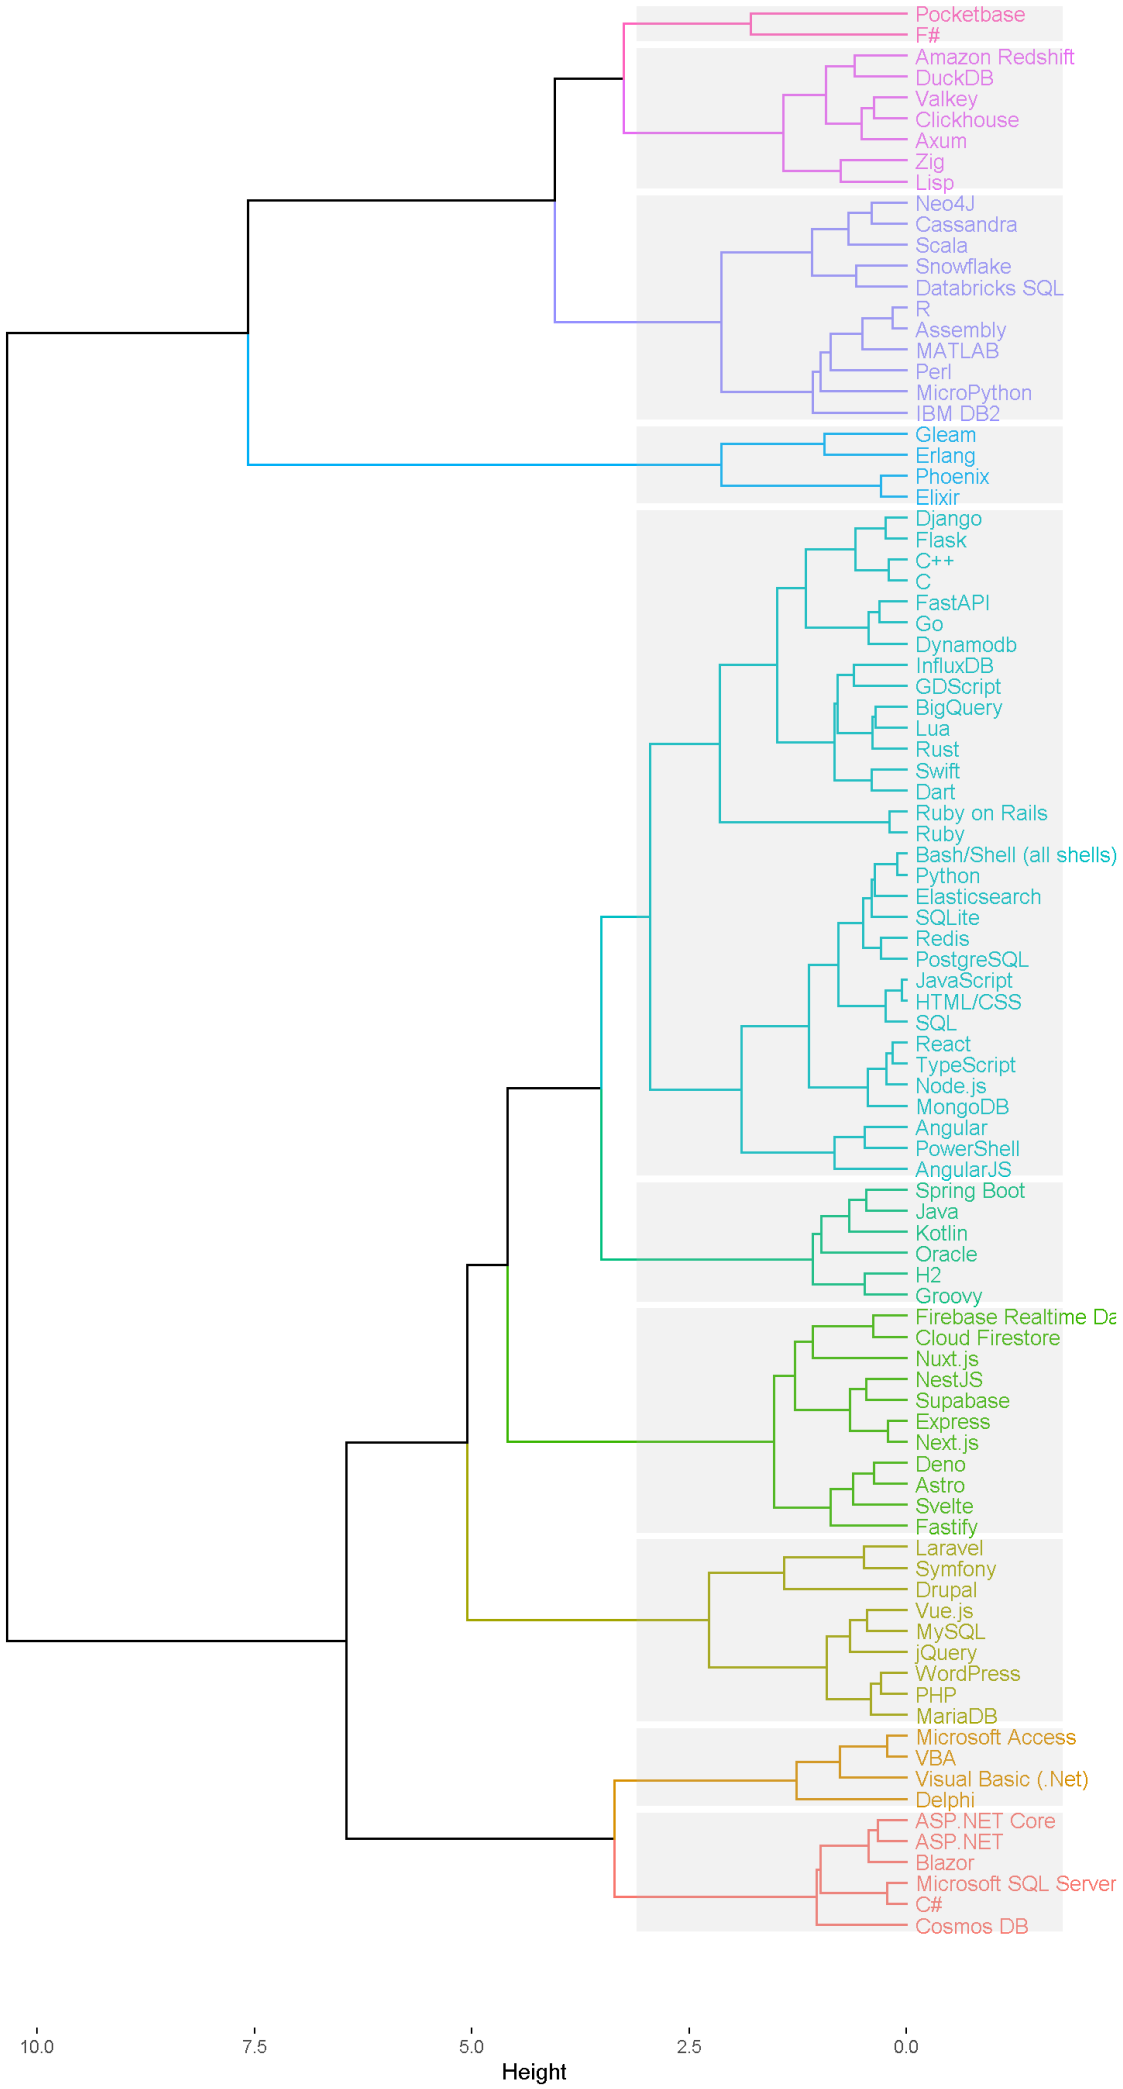

Na podstawie analizy wykresu wyodrębniono:

Ekosystem .NET - Microsoft

Zbiór technologii rozwijanych przez firmę Microsoft do budowania nowoczesnych aplikacji biznesowych i serwerowych.

Windows Legacy

Starsze technologie (tzw. legacy) oraz narzędzia do tworzenia aplikacji desktopowych. Często wykorzystywane do automatyzacji biurowej i utrzymania systemów Microsoftu sprzed lat.

Ekosystem PHP i CMS

Starsze rozwiązania internetowe. Dominuje tu PHP wraz ze swoimi frameworkami (Laravel, Symfony) oraz systemami CMS - *Content Management System* (WordPress, Drupal).

Nowoczesne frameworki JavaScript

Grupa najnowszych narzędzi służących do budowania dynamicznych i szybkich aplikacji internetowych. Są to technologie typu fullstack - pozwalają tworzyć zarówno to, co widzi użytkownik, jak i to, co dzieje się na serwerze.

Technologie korporacyjne Java

Rozwiązania oparte na języku Java, wykorzystywane głównie przez banki i korporacje. Służą do budowania ogromnych, bezpiecznych systemów, które muszą obsługiwać miliony operacji.

Technologie ogólnego przeznaczenia

Główne technologie rynku IT. Obejmują najpopularniejsze bazy danych (PostgreSQL), języki systemowe (C, C++), języki prezentacji treści oraz języki skryptowe (PowerShell).

Ekosystem BEAM

Technolgie oparte na maszynie wirtualnej Erlanga, ich cechą charakterystyczną jest duża odporność na awarie i możliwość obsługi dużej liczby procesów.

Analityka danych i Big Data

Silny nacisk technologii na przetwarzanie danych i naukę (R, MATLAB, Scala, Databricks, Snowflake). Znajdują się tu też starsze technologie specjalistyczne (Perl, Assembly, IBM DB2).

Specjalistyczne bazy danych

Bardzo wydajne systemy bazy danych do analityki (Redshift, DuckDB, Clickhouse) oraz nowoczesne narzędzia systemowe (Zig, Axum, Valkey).

Technologie niszowe

To zestaw technologii "alternatywnych" i wysokopoziomowych, często wybieranych do szybkiego tworzenia aplikacji lub specyficznych zadań.

6.3. Hierarchiczne Klastrowanie na Składowych Głównych wyniku MCA

W celu przypisania konkretnej grupy technologicznej do konkretnych respondetów zastosowano Hierarchiczne Klastrowanie na Składowych Głównych (HCPC). Wyodrębniono 10 klastrów sugerując się wynikami uzyskanymi w poprzednim punkcie. W przeciwieństwie do metody HC gdzie klastrowano technologie, metoda HCPC dokonuje klastrowania bezpośrednio na respondentach ankiety biorąc pod uwagę analizę korespondencji technologii. Tabela przedstawia klastry wynikowe HCPC wraz ich liczebnością oraz 3 technologiami które miały największy udział w definiowaniu klastra. Udział jest tu rozmiany przez wartość v-test. Im wyższa wartość dodatnia, tym bardziej dana technologia reprezentowana w tym klastrze w porównaniu do całego zbioru danych. Nazwy klastrów określono na podstawie technologii.

Profil	Liczebność	Technologie
Ekosystem Microsoft	3269	Blazor, ASP.NET.Core, ASP.NET
Backend	4064	Express, ASP.NET.Core, Node.js
Frontend	3739	React, Node.js, TypeScript
Klasyczne Systemy Internetowe	2782	Laravel, Symfony, MariaDB
Zarządzanie bazami danych MS	1187	ASP.NET.Core, ASP.NET, Microsoft.SQL.Server
Złożone systemy biznesowe (Java)	2503	Spring.Boot, H2, Java
Przetwarzanie w Czasie Rzeczywistym	660	Phoenix, Elixir, Erlang
Nowoczesne aplikacje pełnowymiarowe	1641	Express, Node.js, Next.js
Inżynieria niskopoziomowa	433	C, C++, Assembly
Technologie eksperymentalne	41	Pocketbase, Gleam, Scala

6.4. Eksploracyjna Analiza Czynnikowa

W celu zidentyfikowania ukrytych wymiarów kształtujących profil współczesnego dewelopera, zastosowano metodę Eksploracyjnej Analizy Czynnikowej (EFA). Wybór tej metody jest uzasadniony jej zdolnością do wykrywania zmiennych latentnych, które są nieobserwowalnych bezpośrednio i tłumaczą korelacje między wieloma odpowiedziami w ankiecie. Metoda idealnie nadaje się do analizy zmiennych mierzonych na skalach Likerta, pozwalając na redukcję szumu informacyjnego i zastąpienie zestawu pojedynczych pytań kilkoma kluczowymi konstruktami teoretycznymi, takimi jak „optymizm wobec AI" czy „zaufanie do technologii". W efekcie analiza ta pozwoli na zrozumienie głębokich struktur motywacyjnych deweloperów, co w połączeniu z wcześniej wykonaną analizą MCA umożliwi precyzyjne przypisanie postaw psychologicznych do konkretnych segmentów technologicznych branży IT.

Do przeprowadzenia analizy EFA wybrano zmienne odzwierciedlające doświadczenie, satysfakcję oraz szerokie spektrum interakcji z rozwiązaniami AI:

- "WorkExp" (Ile masz lat doświadczenia zawodowego?)
- "EdLevel" (Jaki jest twój poziom wykształcenia formalnego?)
- "JobSat" (Jaki odczuwasz poziom satysfakcji z roli dewelopera?)
- "AIThreat" (Czy AI to zagrożenie dla pracy?)
- "AISelect" (Czy używasz narzędzi AI w pracy?)
- "AISent" (Jaki jest twój stosunek do używania AI?)
- "AIAcc" (Jakie jest twoje zaufanie do dokładności AI?)
- "AIComplex" (Jak oceniasz radzenie sobie AI ze złożonymi zadaniami?)
- "AIAgents" (Czy używasz agentów AI?)
- "LearnCodeAI" (Czy uczyłeś się programowania AI?)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = poly_matrix$rho)
## Overall MSA =  0.78
## MSA for each item =
##     WorkExp     EdLevel      JobSat    AIThreat    AISelect      AISent
##        0.35        0.62        0.58        0.61        0.74        0.79
##       AIAcc   AIComplex    AIAgents LearnCodeAI
##        0.81        0.75        0.88        0.86
```

Rozpoczęcie EFA wymaga potwierdzenia, czy posiadany zbiór danych jest odpowiedni do strukturyzowania go w mniejsze wymiary. Narzędziem służącym do tej weryfikacji jest test Kaiser-Meyer-Olkin, który mierzy adekwatność doboru zmiennych.

Globalny współczynnik adekwatności próby wynosi 0,78. Według powszechnie przyjętych kryteriów statystycznych, wynik mieszczący się w przedziale 0,70–0,80 jest uznawany za satysfakcjonujący. Oznacza to, że korelacje między zmiennymi są wystarczająco silne, aby przeprowadzenie analizy czynnikowej było uzasadnione i pozwoliło na wyłonienie wiarygodnych czynników latentnych.

Szczegółowa analiza wskaźników MSA dla poszczególnych zmiennych pozwala zidentyfikować, które z nich najlepiej budują strukturę czynnikową. Zmienne dotyczące sztucznej inteligencji wykazują doskonałe wyniki. Tak wysokie wartości świadczą o tym, że te zmienne dzielą ze sobą bardzo dużą część wspólnej wariancji. Z dalszej analizy wyeliminowane zostały zmienne o wartościach wskaźnika poniżej 0,7 (JobSat, EdLevel, WorkExp) poaza zmienną AIThreat (0,61), której wyników w analizie EFA byliśmy ciekawi.

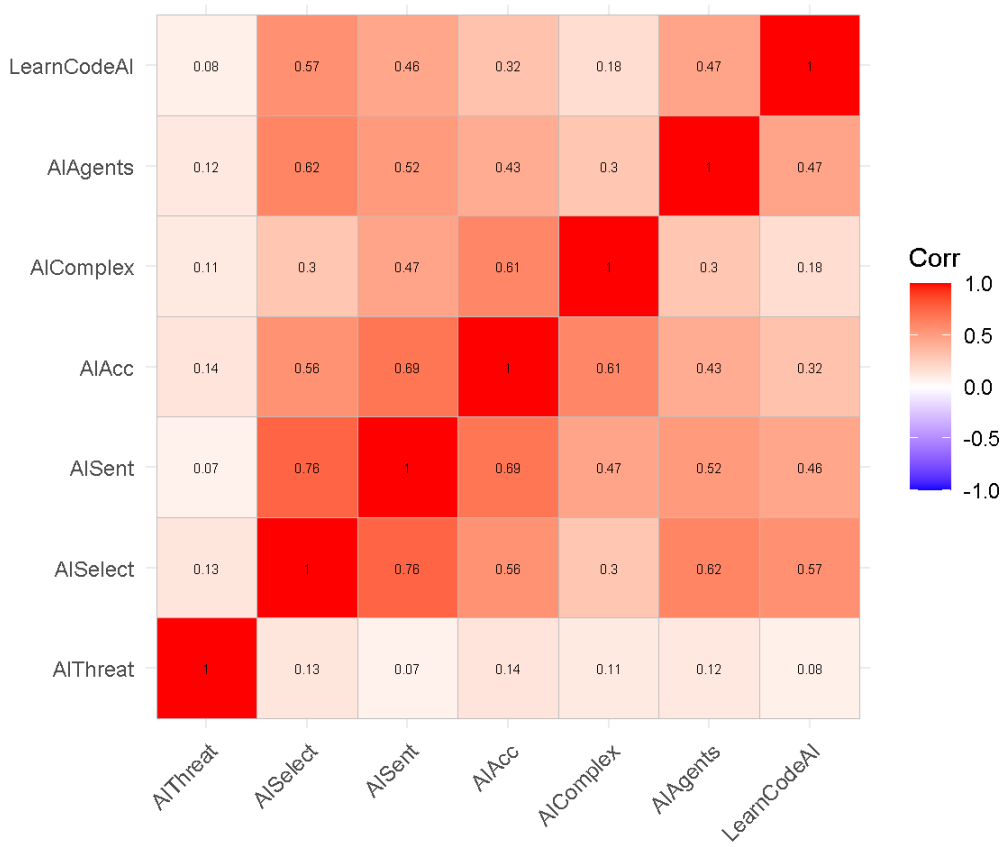

Wykorzystanie macierzy korelacji polichorycznych pozwoliło na rzetelną kwantyfikację relacji między zmiennymi porządkowymi, co jest kluczowe dla poprawności statystycznej modeli opartych na skalach porządkowych. W strukturze macierzy zidentyfikowano wyraźną agregację kluczowych konstruktów zaufania do dokładności AI, stosunku do używania AI oraz radzenia sobie AI ze złożonymi zadaniami.

Test sferyczności Bartletta

```
## $chisq
## [1] 61485.94
##
## $p.value
## [1] 0
##
## $df
## [1] 21
```

Ostatnim krokiem weryfikującym zasadność przeprowadzenia EFA jest test sferyczności Bartletta, którego wyniki stanowią statystyczne potwierdzenie dla wcześniej zaobserwowanych korelacji w

macierzy polichorycznej. Test ten służy do zweryfikowania hipotezy zerowej, która zakłada, że macierz korelacji jest macierzą jednostkową.

Wyniki przeprowadzonego badania dostarczają bardzo silnych dowodów na korzyść modelowania czynnikowego. Wskaźnik p-value wynosi 0, pozwala to na odrzucenie hipotezy zerowej. Wynik stanowi potwierdzenie, że zmienne w zbiorze danych są ze sobą istotnie skorelowane.

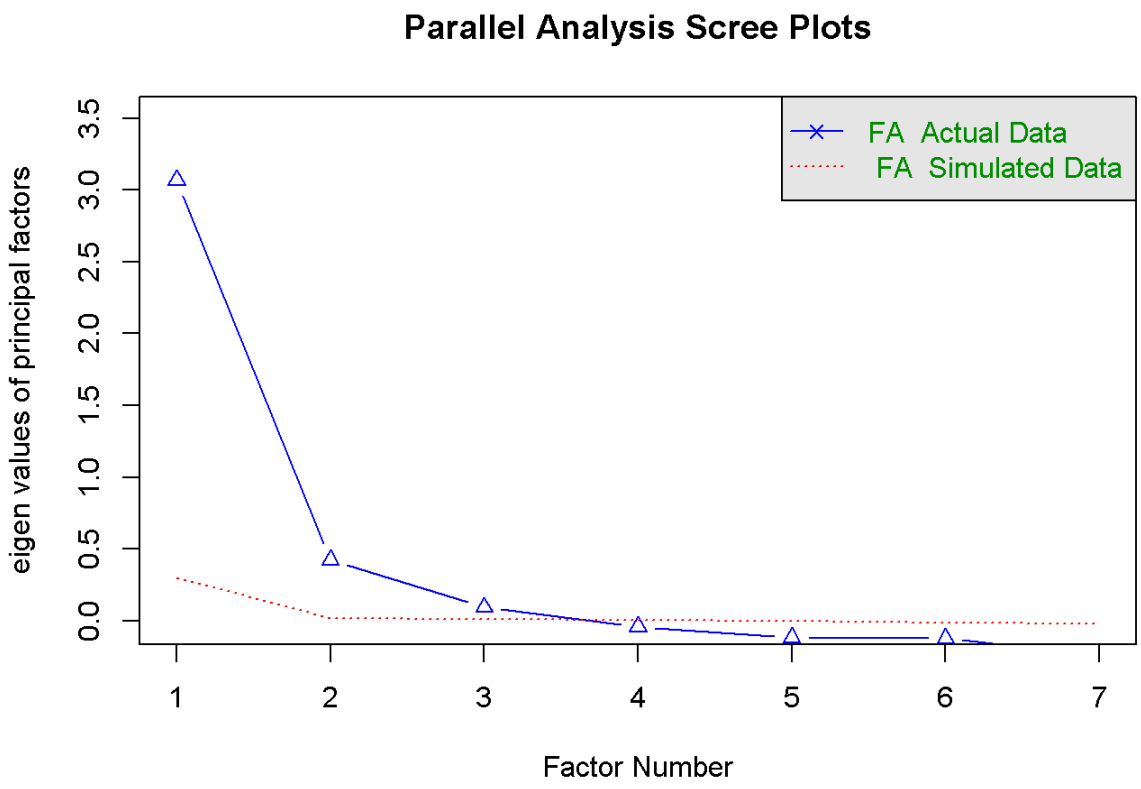


```
## Parallel analysis suggests that the number of factors =  3
```

Kolejnym krokiem przed przystąpieniem do ostatecznej rotacji czynników jest analiza równoległa. Jest to jedna z najbardziej obiektywnych metod wyznaczania liczby czynników, które należy zatrzymać w modelu EFA. W modelu EFA zatrzymujemy tylko te czynniki, dla których wartości własne z danych rzeczywistych znajdują się powyżej linii danych symulowanych. Na podstawie analizy przebiegu obu linii na wykresie, można sformułować następujący wniosek, że istnieje konieczność wyodrębnienia 3 czynników.

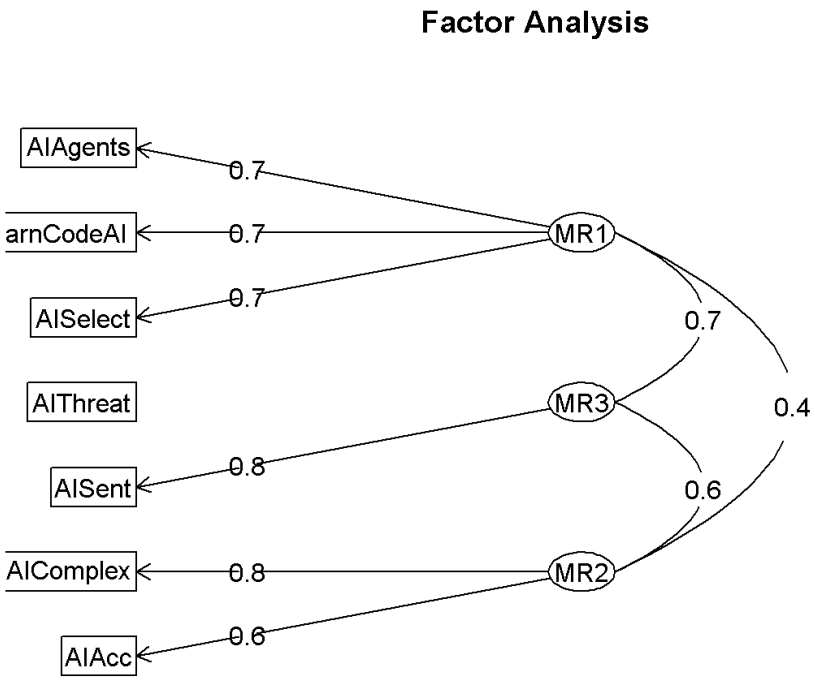


```
##
## Loadings:
##             MR1    MR3    MR2
## AIThreat
## AISelect     0.657  0.342
## AISent              0.846
## AIAcc               0.301  0.565
## AIComplex                  0.811
## AIAgents     0.739
## LearnCodeAI  0.682
##
##                  MR1   MR3   MR2
## SS loadings    1.506 0.973 1.041
## Proportion Var 0.215 0.139 0.149
## Cumulative Var 0.215 0.354 0.503
```

Wyniki Eksploracyjnej Analizy Czynnikowej pozwalają na wyodrębnienie trzech głównych wymiarów, które tłumaczą łącznie 50,3% całkowitej wariancji postaw deweloperów wobec AI.

Czynnik MR1: Adopcja AI (21,5% wariancji)

Jest to najsilniejszy wymiar, który grupuje zmienne związane z aktywnym wdrażaniem AI do codziennego warsztatu pracy oraz inwestowaniem czasu w naukę tych technologii. Najwyższe ładunki posiadają AIAgents (0,739) oraz LearnCodeAI (0,682), wspierane przez AISelect (0,657).

Czynnik MR2: Ocena AI (14,9% wariancji)

Wymiar ten koncentruje się na technicznym zaufaniu do jakości wyników dostarczanych przez sztuczną inteligencję. Dominuje tu zmienna AIComplex (0,811) oraz AIAcc (0,565).

Czynnik MR3: Entuzjazm do AI (13,9% wariancji)

Ostatni czynnik ma charakter bardziej subiektywny i emocjonalny, opisując ogólny stosunek dewelopera do nowej fali technologicznej. Najsilniejszy ładunek ma zmienna AISent (0,846) Znacznie słabsze powiązanie wykazują zmienne AISelect (0,342) oraz AIAcc (0,301).

Warto zwrócić uwagę, że zmienna dotycząca lęku przed AI nie uzyskała istotnego ładunku w żadnym z czynników. Potwierdza to wcześniejsze obserwacje z macierzy korelacji.

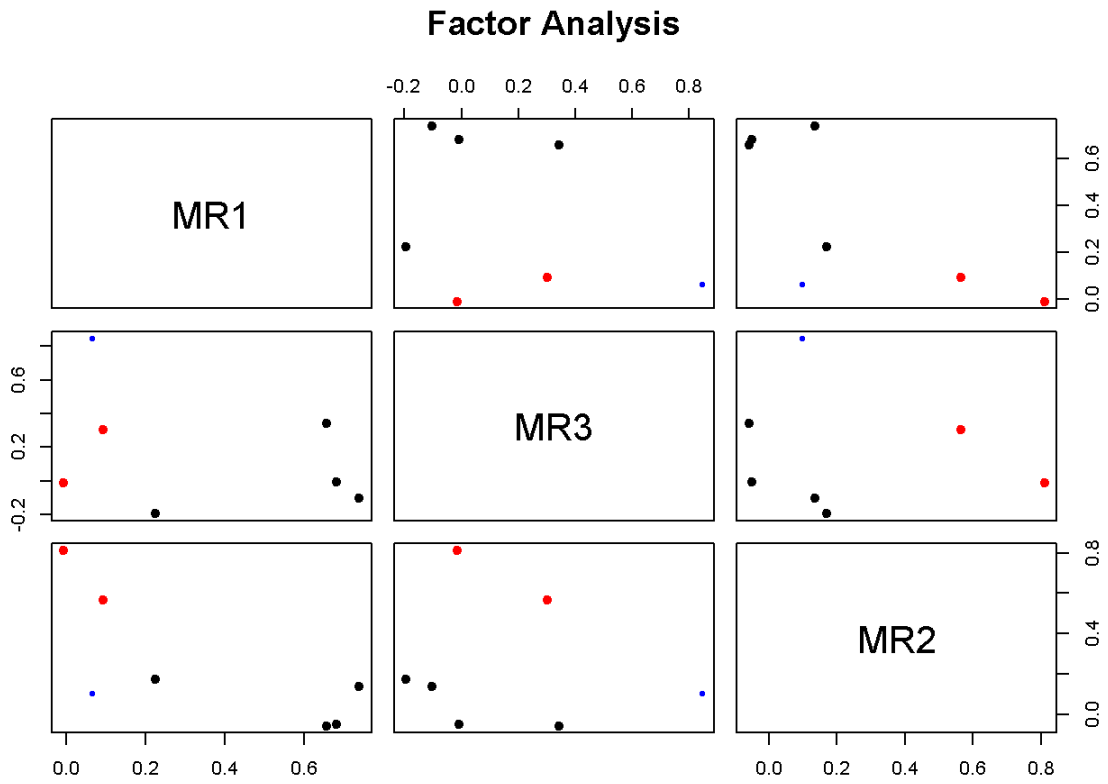

Wykres stanowi wizualną mapę ładunków czynnikowych, przedstawiając rozmieszczenie badanych zmiennych w przestrzeni trzech wyodrębnionych wymiarów MR1, MR2 oraz MR3. Kropki reprezentujące poszczególne zmienne są wyraźnie pogrupowane wzdłuż osi czynników. Oznacza to, że większość pytań silnie definiuje tylko jeden konkretny wymiar, nie wykazując przy tym kłopotliwych, silnych ładunków krzyżowych. Na wykresie MR1 widać wyraźne wysunięcie zmiennych związanych z zaawansowaną adopcją, takich jak agenci AI, podczas gdy na osi MR3 dominuje odosobniony punkt odpowiadający ogólnemu nastawieniu. Na wykresach korelujących z MR2 widać skupienie punktów dotyczących zaufania i złożoności technicznej, które wyraźnie oddzielają się od sfery czysto emocjonalnej MR3 czy edukacyjnej MR1.

7. Porównanie metod

Profil (Klaster)	MR1 - Adopcja AI	MR2 - Ocena AI	MR3 - Entuzjazm AI	Strach	Doświadczenie	Satysfakcja	Edukacja
Ekosystem Microsoft	-0.006	-0.017	0.009	0.462	2.736	2.867	4.817
Backend	0.014	0.065	0.005	0.501	2.529	2.828	5.050
Frontend	-0.012	-0.015	-0.004	0.539	2.151	2.822	4.807
Klasyczne Systemy Internetowe	-0.017	-0.011	-0.004	0.503	2.614	2.832	4.560
Zarządzanie bazami danych MS	-0.057	-0.070	-0.068	0.430	2.642	2.868	4.657
Złożone systemy biznesowe (Java)	-0.066	-0.034	-0.034	0.458	2.245	2.846	4.933
Przetwarzanie w Czasie Rzeczywistym	0.008	-0.010	0.025	0.435	2.502	2.949	4.588
Nowoczesne aplikacje pełnowymiarowe	-0.019	-0.008	-0.032	0.499	2.108	2.874	4.613
Inżynieria niskopoziomowa	-0.101	0.042	-0.061	0.456	2.380	2.771	4.821
Technologie eksperymentalne	0.025	-0.402	-0.065	1.083	2.333	3.000	4.800

Powyższa tabela stanowi ostateczną syntezę całego procesu badawczego, rzutując wyniki czynnikowe postaw na wyodrębnione ekosystemy technologiczne. Choć dane operują na wynikach wyśrodkowanych wokół zera oraz średnich punktowych, co pozwala na precyzyjną diagnostykę, to przy głębszej analizie widać przede wszystkim dużą spójność środowiska deweloperskiego. Różnice między poszczególnymi klastrami, choć mierzalne, rzadko przyjmują formę radykalnych rozbieżności, co sugeruje, że branża IT jako całość wypracowała dość wyrównane, pragmatyczne podejście do narzędzi generatywnych.

Zależność między stażem pracy a deklarowanym poziomem strachu przed sztuczną inteligencją jest widoczna, ale jej skala pozostaje umiarkowana. Ekosystem Microsoft, reprezentujący grupę o najwyższym średnim doświadczeniu, wykazuje jeden z niższych poziomów lęku, oscylujący wokół wartości 0,462. Gdy zestawimy to z klastrem Frontend, gdzie doświadczenie jest statystycznie mniejsze, poziom niepokoju rośnie zaledwie do wartości 0,539. Tak niewielkie odchylenia

świadczą o tym, że bez względu na pozycję rynkową, większość specjalistów postrzega AI w podobny sposób jako kolejny etap ewolucji narzędziowej niż zagrożenie.

Ciekawie prezentuje się korelacja między wykształceniem a merytoryczną oceną technologii oraz entuzjazmem. Klaster Backend, posiadający najwyższy wskaźnik edukacji, notuje najwyższą pozytywną ocenę jakościową AI, zachowując przy tym neutralny entuzjazm emocjonalny. Podobny wzorzec widać w inżynierii niskopoziomowej. Mimo nieco niższej oceny możliwości narzędzi, ich emocjonalny stosunek do AI nie odbiega drastycznie od średniej rynkowej. Sugeruje to, że wysokie kompetencje sprzyjają chłodnej, technicznej ocenie użyteczności algorytmów, przy jednoczesnym braku ulegania rynkowemu „hype'owi", co jest cechą wspólną dla większości doświadczonych inżynierów.

Nawet w grupie technologii eksperymentalnych, która na tle zestawienia wydaje się najbardziej specyficzna, punkty wspólne z resztą branży są wyraźne. Choć deweloperzy ci deklarują wyższy poziom odczuwanego strachu, ich satysfakcja z pracy jest tylko o ułamek wyższa od średniej w innych klastrach, takich jak Backend czy Ekosystem Microsoft. Ich krytyczna ocena jakości wyników AI przy relatywnie wysokiej adopcji sugeruje postawę „ostrożnego pioniera", który używa nowinek, by utrzymać konkurencyjność, ale robi to z podobnym dystansem, jaki cechuje całe środowisko IT.

8. Wnioski z analizy

Wykorzystane metody wielowymiarowej analizy danych pozwoliły odpowiedzieć na pytania zadane na początku projektu:

1. Na jakie segmenty pod kątem wykorzystywanych technologii dzieli się rynek IT?

Na podstawie Wielowymiarowej Analizy Korespondencji MCA przeprowadzono Klastrowanie Hierarchiczne (HC) oraz Hierarchiczne Klastrowanie na Składowych Głównych HCPC, które pozwoliło wyróżnić 10 segmentów rynku IT pod kątem wykorzystywanych przez deweloperów technologii. Wyróżnionymi segmentami są:

HC	HCPC
Ekosystem .NET – Microsoft	Ekosystem Microsoft
Windows Legacy	Backend
Ekosystem PHP i CMS	Frontend
Nowoczesne frameworki JavaScript	Klasyczne Systemy Internetowe
Technologie korporacyjne Java	Zarządzanie bazami danych MS
Technologie ogólnego przeznaczenia	Złożone systemy biznesowe (Java)
Ekosystem BEAM	Przetwarzanie w Czasie Rzeczywistym
Analityka danych i BigData	Nowoczesne aplikacje pełnowymiarowe
Specjalistyczne bazy danych	Inżynieria niskopoziomowa
Technologie niszowe	Technologie eksperymentalne

2. W jakim stopniu przedstawiciele tych grup boją się zastąpienia przez AI?

Na podstawie eksploracyjnej analizy danych ogólny lęk respondentów z branży IT jest niski. Dowodzi temu mediana odpowiedzi na pytanie ankietowe dotyczące poczucia zagrożenia w stosunku do AI. Wartość mediany wyniosła 0, co dowodzi braku poczucia zagrożenia. Warto jednak podkreślić, że w ankiecie brali udział deweloperzy korzystający z platformy Stack Overflow, którzy średnio mają między 11 a 20 lat doświadczenia. Pomimo tego, że zróżnicowanie między sektorami nie jest duże i narzędzia AI są raczej postrzegane jako narzędzia wspomagające, a nie zagrożenie. Porównując jednak relacje w konkretnych klastrach, stosunkowo najmniejsze obawy mają: zarządzanie bazami danych MS, przetwarzanie w czasie rzeczywistym oraz inżynieria niskopoziomowa. Z kolei największym strachem charakteryzują się klastry: technologie eksperymentalne, frontend oraz klasyczne systemy internetowe.

3. W jakim stopniu adaptują się do technologii AI?

Rynek IT w 2025 roku charakteryzuje się wysoką adopcją narzędzi AI, co potwierdzają rozkłady zmiennych wskazujące na koncentrację odpowiedzi w górnych rejestrach skali. Sztuczna inteligencja stała

się standardem pracy na równi z IDE czy systemami kontroli wersji. Z danych wynika, że najwyższy wskaźnik adopcji AI wykazują specjaliści z grupy Technologie eksperymentalne oraz Backend. Ci pierwsi, mimo najwyższego poziomu lęku przed technologią, są liderami w testowaniu nowych rozwiązań.

Barierą adopcji nie jest brak edukacji – która utrzymuje się na stabilnym, wysokim poziomie we wszystkich grupach – lecz specyfika techniczna. Największy opór i najniższą adopcję obserwujemy w Inżynierii niskopoziomowej oraz w Złożonych systemach biznesowych Java. Sugeruje to, że w obszarach wymagających najwyższej precyzji, optymalizacji i pracy z krytyczną architekturą, obecne narzędzia AI nie dostarczają jeszcze satysfakcjonujących rezultatów, co potwierdzają również ujemne wskaźniki oceny użyteczności w tych sektorach.

4. Jak oceniają jakość narzędzi AI w stosunku do ich segmentów technologicznych?

Jakość narzędzi AI jest oceniana najwyżej tam, gdzie tolerancja na drobne błędy jest wyższa, a korzyści z automatyzacji powtarzalnych zadań są natychmiastowe aplikacje webowe, systemy biznesowe. W obszarach krytycznych, wymagających absolutnej precyzji i kontroli nad jakością i optymalizacją kodu. Obecna generacja narzędzi AI jest oceniana jako niewystarczająca jakościowo, co skutecznie hamuje ich adopcję w tych sektorach rynku.

Branża IT, mimo zróżnicowania specjalizacji, generalnie nie postrzega sztucznej inteligencji jako zagrożenia, lecz traktuje ją jako standardowe narzędzie wspomagające, co potwierdza wysoka adopcja przy niskim poziomie lęku. Mimo powszechności rozwiązań, widoczny jest wyraźny podział, w którym sektory eksperymentalne i webowe wdrażają AI najszybciej, podczas gdy obszary wymagające najwyższej precyzji i bezpieczeństwa pozostają sceptyczne. Zdaniem autorów AI nie stanowi zagrożenia na rynku IT dla doświadczonych specjalistów, natomiast juniorzy mogą rywalizować z AI w zakresie automatyzacji prostych zadań. Próg wejścia do branży IT zdecydowanie się podniósł, jednak na ten moment AI nie eliminuje człowieka, a zmienia zakres jego obowiązków i kładzie większy nacisk na krytyczne myślenie w kontekście do wyników generowanych przez LLM.

Projekt w wersji html oraz kod źródłowy